Prédiction du score d'examen

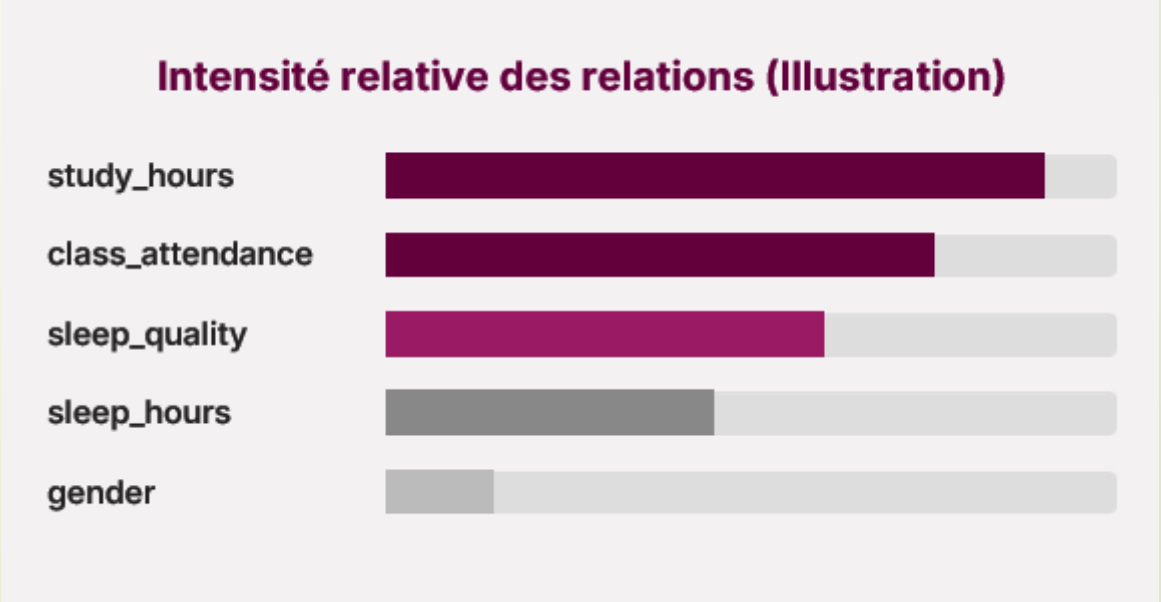
Anass, John-Michael, Sayfe-Din, Selim

Contexte & Données

- Objectif : Régression tabulaire (exam_score)
- Volume : 630k (Train) / 270k (Test)
- Intégrité : 0 valeur manquante, 0 doublon
- Zéro imputation requise ? Focus 100% Modélisation

Analyse Exploratoire

- Top Corrélations : study_hours (0.76), class_attendance (0.36)
- Démographie : Âge et genre sans impact
- Comportement : Impact majeur du sommeil et des méthodes d'étude



Feature Engineering

- Signaux cycliques : Sinus (12, 14, 20) sur le temps d'étude
- Ratios croisés : study_hours / sleep_hours
- Projections OLS : Pondération mathématique des axes
- Heuristiques métier : Bonus/Malus (qualité du sommeil, méthodes)

Prétraitement & Filtrage

- Target Encoding (cv=5) ? Prévention du Data Leakage
- Standardisation ? StandardScaler
- Sélection (SFS) ? Réduction stricte au Top 15 features

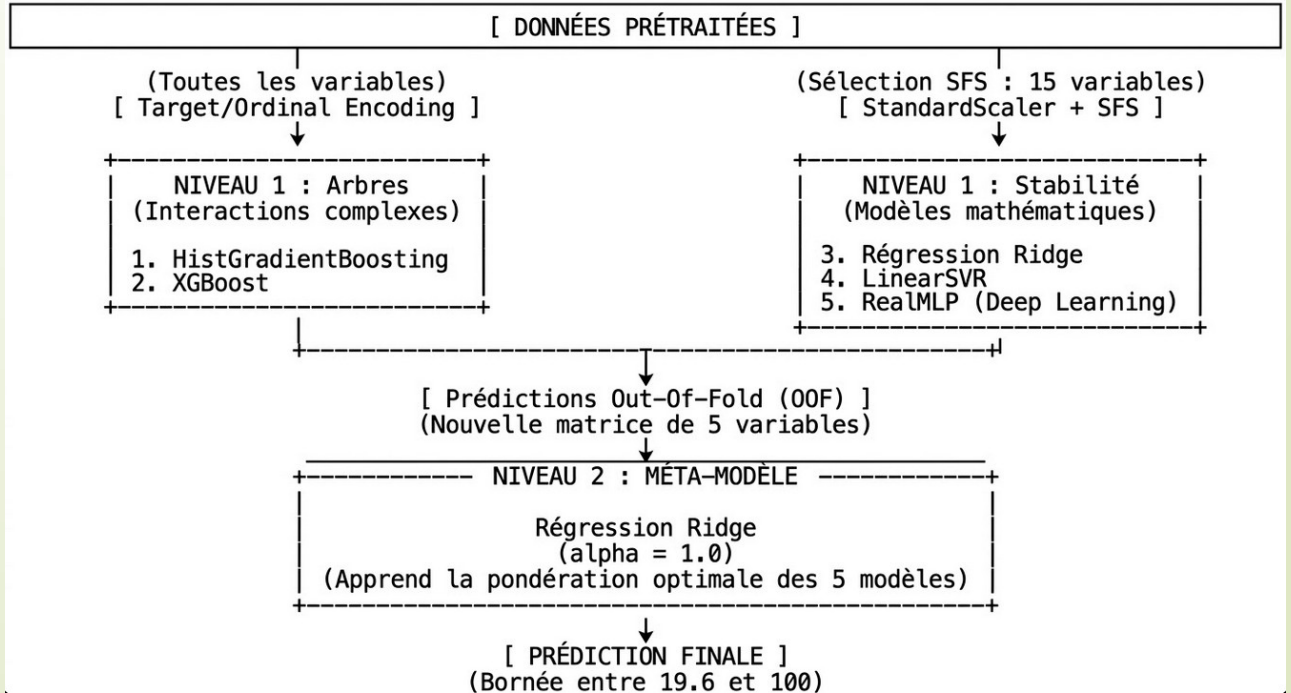


Recherche & Optimisation

- Benchmark Initial (10+ modèles):
  - Tests de référence : Dummy, Lasso, ElasticNet, Random Forest
  - Constat : Supériorité immédiate des modèles de Boosting
- Approche XLearn & FM:
  - Target Encoding massif et interactions complexes
  - Performance XGBoost isolé : 8.680 RMSE
- Optimisation Optuna:
  - Tuning fin des hyperparamètres par itérations
  - Ajustement post-SFS pour garantir la précision

Architecture : Stacking à 2 Niveaux

- Niveau 1 (5 Modèles) :
  - Arbres (Toutes les features) : HGBR, XGBoost
  - Stabilité (Top 15) : Ridge, LinearSVR, RealMLP
- Niveau 2 (Méta-Modèle) :
  - Régression Ridge (Lissage des erreurs résiduelles)



Validation & Ablation

- Protocole : 10-Fold CV (OOF)
- Chute de la RMSE :
  - Baseline : 8.781
  - Feature Engineering : 8.743
  - Stacking (5 modèles) : 8.658

Configuration	RMSE (CV)
Modèle de base	**8.781**
Feature engineering (interactions, ratios, sinus features)	**8.743**
Premier Stacking (3 modèles : HGBR, Ridge, LinearSVR)	**8.701**
Modèle XGBoost isolé puissant	**8.680**
Stacking (HGBR+XGBoost+RealMLP + Ridge + SVR)	**8.658**

Conclusion & Classement Kaggle

- Score Local (CV) : 8.658
- Score Kaggle Public : 8.624
- Classement : Top 650 / ~4300 équipes
- Clé du succès : Feature Engineering + Diversité de modèles

644	▲ 3	ismailcanoguz		8.62151	3	1mo
645	▲ 11	JinZhao		8.62387	1	2mo
646	▲ 13	Keya Dobriyal		8.62462	29	1mo
647	▲ 3	Rattan Singh		8.62515	34	1mo
648	▲ 3	strongdogking		8.62545	33	1mo
649	▲ 8	shane18		8.62557	61	1mo
650	▲ 14	CJ ROCKBALL		8.62817	20	2mo